

文章编号: 1007-4929(2022)03-0067-08

基于深度学习及传统机器学习模型估算 山东省参考作物蒸散量

任传栋, 王志真, 马 钊, 张 敏

(山东省水利勘测设计院, 济南 250013)

摘 要: 为探寻深度学习模型在区域参考作物蒸散量 (Reference crop evapotranspiration, ET_0) 估算中的适用性, 以山东省为研究区域, 选取了深度神经网络 (DNN)、时间卷积神经网络 (TCN) 和长短期记忆神经网络 (LSTM) 3种深度学习模型, 极限学习机模型 (ELM)、广义回归神经网络模型 (GRNN) 和随机森林模型 (RF) 3种传统机器学习模型, Hargreaves-Samani 模型 (HS)、Droogers-Allen 模型 (DA)、Priestley-Taylor 模型 (PT)、Marrink 模型 (MK)、WMO 模型 (WMO)、Trabert 模型 (TRA) 6种经验模型, 以均方根误差 (RMSE)、决定系数 (R^2)、平均绝对误差 (MAE) 和效率系数 (E_n) 为精度评价体系, 找出了适用于山东省 ET_0 估算的最优模型, 结果表明: 相同气象参数输入条件下, 机器学习模型精度普遍优于经验模型, 而3种深度学习模型精度最优, TCN 模型在所有模型中精度最高; 输入辐射资料的模型精度普遍高于温度模型和质量传输模型, TCN2 模型 GPI 为 1.036, 在所有模型中排名第1。因此, TCN 模型为山东省 ET_0 的最优估算模型使用。

关键词: 山东省; 参考作物蒸散量; 深度学习; 机器学习; 辐射资料; 估算模型

中图分类号: S271; TV642.4 **文献标识码:** A

任传栋, 王志真, 马 钊, 等. 基于深度学习及传统机器学习模型估算山东省参考作物蒸散量[J]. 节水灌溉, 2022(3): 67-74.

REN C D, WANG Z Z, MA Z, et al. Estimation of reference crop evapotranspiration in Shandong province based on deep learning and traditional machine learning model[J]. Water Saving Irrigation, 2022(3): 67-74.

Estimation of Reference Crop Evapotranspiration in Shandong Province Based on Deep Learning and Traditional Machine Learning Model

REN Chuan-dong, WANG Zhi-zhen, MA Zhao, ZHANG Min

(Shandong Survey and Design Institute of Water Conservancy, Jinan 250013, China)

Abstract: In order to explore the applicability of deep learning models in the estimation of regional reference crop evapotranspiration (ET_0), this paper took Shandong Province as the research area and selected 3 deep learning models (including deep neural network (DNN), time convolutional neural network (TCN) and long short-term memory neural network (LSTM)), 3 traditional machine learning models (including extreme learning machine model (ELM), generalized regression Neural network model (GRNN) and random forest model (RF)), and 6 empirical models (including Hargreaves-Samani model (HS), Droogers-Allen model (DA), Priestley-Taylor model (PT), Marrink model (MK), WMO model (WMO), Trabert model (TRA)). Taking Root mean square error (RMSE), coefficient of determination (R^2), average absolute error (MAE) and efficiency coefficient (E_n) as the accuracy evaluation system, the optimal model for ET_0 estimation in Shandong province was found. The results showed that the accuracy of the machine learning model was generally better than that of the empirical model under the same meteorological parameter input conditions, while the three deep learning models had the best accuracy, and the TCN model had the highest accuracy among all models. The accuracy of the model with radiation data input was generally higher than that of the temperature model and the mass transfer model. The GPI of the TCN2 model was 1.036, ranking first among all models. So the TCN model can be used as a recommended model for ET_0 estimation in Shandong Province.

Key words: Shandong province; reference crop evapotranspiration; deep learning; machine learning; radiation data; estimation model

收稿日期: 2021-09-17

基金项目: 国家科技支撑项目 (31410005321403)。

作者简介: 任传栋 (1983-), 男, 硕士, 高级工程师, 从事水利工程设计。E-mail: 253510814@qq.com。

0 引言

蒸散 (Evapotranspiration, ET) 由植株蒸腾与株间蒸发 2 部分组成, 其值的准确估算对灌溉需水量确定及农田生态系统评价意义重大^[1,2]。参考作物蒸散量 (Reference crop evapotranspiration, ET_0) 的估算精度在一定程度上决定了 ET 的估算精度, 它是作物系数法估算区域 ET 的重要参数之一^[3]。FAO-56 分册规定的 Penman-Monteith (PM) 模型综合考虑了能量平衡和空气动力学的相关理论, 是估算 ET_0 的标准模型^[4,5]。PM 模型计算时涉及到了多个气象参数, 例如最高温度、最低温度、相对湿度、风速等, 这使得该模型的广泛应用性受到了一定的限制^[6]。因此, 研究区域 ET_0 估算的简化模型, 在保证估算精度的前提下使用较少的气象参数, 这对区域灌溉决策的制定具有十分重要的意义。

为更好地估算区域 ET_0 , 研究学者采用了多种 ET_0 简化计算的模型, 例如温度模型、辐射模型、质量传输模型、蒸发皿模型等, 在这些模型中, 温度模型、辐射模型和质量传输模型的应用较广泛^[7,8]。Almorox 等^[9]研究比较了 11 种温度模型的计算精度, 指出了 Hargreaves (HS) 模型精度最高; 杨永刚等^[10]在中国三大灌区比较了 8 种温度模型的精度, 指出 HS 模型在河套灌区的精度最高; Feng 等^[11]比较了 Priestley-Taylor (PT)、Makkink (MK) 和 Ritchie (RC) 3 种辐射模型的精度, 指出 PT 模型在 3 种辐射模型中的精度最高; 吴宗俊等^[12]利用差分进化算法对 MK 模型进行了改进, 并在四川盆地验证了该模型精度, 指出改进后的 MK 模型 R^2 可达 0.87, 精度优于其余模型; 褚荣浩等^[13]比较了质量传输模型与其余 10 种模型的精度, 验证了质量传输模型的适用性。尽管经验模型已表现出了出色的性能, 但它们的性能在不同地区之间存在很大差异^[14]。

近年来, 深度学习模型已在不同领域证明了其精度, 深度学习模型应用最广泛的包括深度神经网络 (DNN)、时间卷积神经网络 (TCN) 和长短期记忆神经网络 (LSTM) 3 种^[14]。Zhang 等^[15]基于 LSTM 模型预测了中国西北干旱地区河套灌区五个分区的地下水位深度动态变化; Wang 等^[16]在地下水流动中验证了 DNN 模型的精度; 邢立文等^[17]在华北地区验证了 LSTM 模型的精度。

深度学习模型已在不同领域取得了较高的精度, 但在 ET_0 估算中的应用仍然较少。为证明深度学习模型在 ET_0 估算中的适用性, 本文以山东省为研究区域, 选择 DNN、TCN 和 LSTM 3 种深度学习模型估算区域 ET_0 , 并将计算结果与传统机器学习模型和经验模型进行对比, 在有限气象资料输入的条件下, 找寻最优模型。

1 研究区域概况与研究方法

1.1 研究区域概况及数据来源

山东省位于我国中东部沿海地区, 属暖温带季风气候区, 降水时空分布不均, 旱涝灾害频发对当地经济造成了严重影响。由于区域地形变化较大, 导致区域水循环差异明显, 因此, 研究山东省的 ET_0 最优估算模型, 对当地防旱防涝政策的

制定具有十分重要的意义。本文选择山东省惠民、青岛、济南等 10 个站点 1980-2018 年的逐日气象数据, 气象数据来自国家气象数据中心, 质量控制良好, 主要包括日最高气温 (T_{\max})、最低气温 (T_{\min})、日照时数 (n)、相对湿度 (RH) 和 10 m 处风速 (U_{10}), 站点分布情况可见图 1。

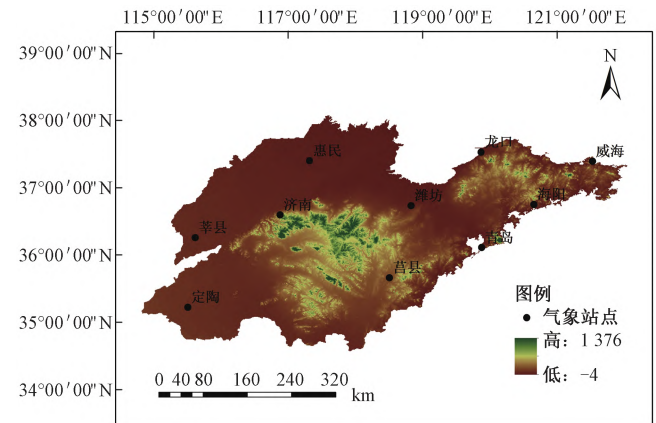


图1 研究区域概况及站点分布

1.2 研究方法

1.2.1 Penman-Monteith 模型

Penman-Monteith 模型 (PM 模型) 可作为 ET_0 计算的标准模型^[4], 具体公式如下:

$$ET_0 = \frac{0.408 \Delta (R_n - G) + \gamma \frac{900}{T + 273} U_2 (e_s - e_a)}{\Delta + \gamma (1 + 0.34 U_2)} \quad (1)$$

式中: R_n 为作物表面的净辐射, $\text{MJ}/(\text{m}^2 \cdot \text{d})$; T 为 2 m 高处的日均气温, $^{\circ}\text{C}$; G 为土壤热量通量密度, $\text{MJ}/(\text{m}^2 \cdot \text{d})$; U_2 为 2 m 高处风速, m/s ; 采用 FAO 推荐方法^[4]由 10 m 风速换算得出; e_s 为饱和水汽压差, kPa ; e_a 为实际水汽压差, kPa ; Δ 为蒸汽压曲线的斜率, $\text{kPa}/^{\circ}\text{C}$; γ 为干湿计常数, $\text{kPa}/^{\circ}\text{C}$ 。

1.2.2 深度学习模型

(1) 长短期记忆神经网络。长短期记忆神经网络模型 (LSTM) 可有效记忆数据历史规律, 避免了传统神经网络模型数据参数的随机性。该模型由输入阀门、遗忘阀门、更新阀门和输出阀门 4 部分组成。通过阀门的开启与关闭, 判定模型计算结果能否满足精度要求, 模型具有步骤可见文献^[17]。

①遗忘阀门。LSTM 模型的遗忘阀门 F_i 基于 sig 激活函数, 读取旧元素的输出值 Y_{i-1} 和新元素的输入值 X_i , 并基于模型权重判定是否应该保留新元素, 原理公式如下:

$$F_i = \sigma(W[Y_{i-1}, X_i] + b) \quad (2)$$

式中: F_i 为模型遗忘阀门; W 为权重; b 为偏执矢量; σ 为 sig 激活函数。

②输入阀门。输入阀门 I_i 可判断输出值能否达到预期, 输入阀门不但可以决定当前元素的输出值 Y_i , 同时可基于 tanh 激活函数创建新的候选变量, 从中选出最优值, 原理公式如下:

$$I_i = \sigma(W[Y_{i-1}, X_i] + b) \quad (3)$$

$$U_i = \tanh(W[Y_{i-1}, X_i] + b) \quad (4)$$

式中: I_i 为模型输入阀门; \tanh 为模型激活函数; U_i 为候选变量, 其余参数含义同上。

③更新阀门。更新阀门 Z_i 将输入阀门与遗忘阀门相乘,

来判断当前元素的状态是否由 S_{i-1} 更新到 S_i , 原理公式如下:

$$S_i = F_i S_{i-1} + I_i Z_i \quad (5)$$

④输出阀门。输出阀门 O_i 计算当前元素的输出值 Y_i , 基于 sig 和 tanh 2 个激活函数最终确定模型输出值, 原理公式如下:

$$O_i = \sigma(W[Y_{i-1}, X_i] + b) \quad (6)$$

$$Y_i = O_i \tanh(S_i) \quad (7)$$

式中: Y_i 为模型输出值; O_i 为输出阀门, 其余参数含义同上。

(2) 时间卷积神经网络。时间卷积神经网络 (TCN) 是 Bai 等^[18]在传统卷积神经网络 (CNN) 的基础上发展起来的。与 CNN 模型相比, TCN 模型具有因果卷积和扩展卷积两个显著的特征, 使得 TCN 模型在解决序列问题上明显优于一些传统神经网络模型, 在 TCN 模型计算中, 时间 t 的输出包含了之前的信息, 这意味着 TCN 模型可以“记忆”更长的过去信息。当考虑随意卷积和扩张卷积时, 时间 t 的输出可用下式表示, 模型具体步骤可见文献^[18]。

$$F(t) = \sum_{i=0}^{K-1} f_i x_{t-i} \quad (8)$$

$$F(t) = \sum_{i=0}^{K-1} f_i x_{t-i d} \quad (9)$$

表 1 经验模型公式及参数

模型类型	序号	模型	计算公式
温度模型	1	Hargreaves-Samani 模型 ^[19] (HS)	$ET_0 = 0.000\ 938 [(T_{\max} - T_{\min})^{0.5}] (T_{\text{mean}} + 17.8) R_a$
	2	Droogres-Allen 模型 ^[20] (DA)	$ET_0 = 0.001\ 22 [(T_{\max} - T_{\min})^{0.4}] (T_{\text{mean}} + 20) R_a$
辐射模型	3	Priestley-Taylor 模型 ^[20] (PT)	$ET_0 = \frac{1.26}{2.45} \frac{\Delta}{\Delta + \gamma} (R_n - G)$
	4	Marrink 模型 ^[21] (MK)	$ET_0 = \frac{0.61}{2.45} \frac{\Delta}{\Delta + \gamma} R_s - 0.12$
质量传输模型	5	WMO 模型 ^[22] (WMO)	$ET_0 = (0.129\ 8 + 0.093\ 4 U_2) (e_s - e_a)$
	6	Trabert 模型 ^[23] (TRA)	$ET_0 = 3.075 U_2^{0.5} (e_s - e_a)$

注:表中各参数含义为: R_n 为作物表面的净辐射, $\text{MJ}/(\text{m}^2 \cdot \text{d})$; G 为土壤热量通量密度, $\text{MJ}/(\text{m}^2 \cdot \text{d})$; U_2 为 2 m 高处的风速, m/s ; e_s 为饱和水汽压差, kPa ; e_a 为实际水汽压差, kPa ; Δ 为蒸汽压曲线的斜率, $\text{kPa}/^\circ\text{C}$; γ 为干湿计常数, $\text{kPa}/^\circ\text{C}$; T_{\max} 、 T_{\min} 、 T_{mean} 分别为日最高、最低和平均温度, $^\circ\text{C}$; R_a 为大气顶层辐射, $\text{MJ}/(\text{m}^2 \cdot \text{d})$; R_s 为地表总辐射, 由温度数据计算得出, $\text{MJ}/(\text{m}^2 \cdot \text{d})$ 。

1.3 模型验证与精度对比

采用 3 种气象参数输入组合训练模型, 分别对应基于辐射、温度的和质量传输的经验模型。基于 1980–2010 年的气象数据训练模型, 2011–2018 年的数据预测模型, 不同气象组合方式可见表 2。

选择均方根误差 (RMSE)、决定系数 (R^2)、平均绝对误差 (MAE) 和效率系数 (E_{ns}) 组成模型精度指标评价体系, 公式如下:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (Y_i - X_i)^2} \times 100\% \quad (10)$$

$$R^2 = \frac{\left[\sum_{i=1}^m (X_i - \bar{X})(Y_i - \bar{Y}) \right]^2}{\sum_{i=1}^m (X_i - \bar{X})^2 \sum_{i=1}^m (Y_i - \bar{Y})^2} \quad (11)$$

$$MAE = \frac{1}{m} \sum_{i=1}^m |X_i - Y_i| \quad (12)$$

$$E_{ns} = 1 - \frac{\sum_{i=1}^m (Y_i - X_i)^2}{\sum_{i=1}^m (X_i - \bar{X})^2} \quad (13)$$

式中: $F(t)$ 为时间 t 的输出函数; f_i 为滤波函数; x_i 为输入项; d 为修正系数; K 为输入项的个数。

(3) 深度神经网络。深度神经网络 (DNN) 是一种新型的人工神经网络模型, 其权值和偏差通过 BP 神经网络模型进行训练。与传统的 BP 神经网络模型相比, DNN 模型具有更多的隐藏层, 使其具有强大的能力来处理许多行业的回归和分类任务, DNN 模型包括两个主要过程, 分别为前馈过程和误差反向传播过程, 具体步骤可见文献^[6]。

1.2.3 传统机器学习模型

为进一步证明深度学习模型的精度, 本文选择了 3 种传统机器学习模型, 分别为极限学习机模型 (ELM)、广义回归神经网络模型 (GRNN) 和随机森林模型 (RF), 在相同气象参数输入的条件下, 比较 3 种传统机器学习模型与 3 种深度学习模型的精度, 3 种传统机器学习模型步骤可见文献^[2]。

1.2.4 经验模型

为进一步验证深度学习模型在不同气象参数输入下的精度, 本文选择了 6 种经验模型进行精度对比, 包括 2 种温度模型、2 种辐射模型和 2 种质量传输模型, 具体公式和参数含义可见表 1。

式中: X_i 和 Y_i 分别为模型模拟值及实测值; \bar{X} 和 \bar{Y} 分别为 X_i 和 Y_i 的平均值。

GPI 指数可整合 4 个指标的综合评价结果^[24], 公式如下:

$$GPI_i = \sum_{j=1}^4 \alpha_j (g_j - y_{ij}) \quad (14)$$

式中: α_j 为常数; MAE 和 $RMSE$ 取 1, E_{ns} 和 R^2 取 -1; g_j 为不同指标的缩放值的中位数; y_{ij} 为不同指标的尺度值。

2 结果与分析

2.1 不同温度模型模拟精度对比

表 3 反映了不同温度模型与 PM 模型计算结果拟合方程斜率对比。表 4 显示, TCN 模型拟合方程斜率最接近标准值“1”, 在不同站点均达到了 0.80 以上。3 种深度学习模型的拟合效果均优于其余模型, 拟合效果由高到低依次为 TCN 模型>LSTM 模型>DNN 模型, 3 种模型拟合方程斜率均在 0.749 以上。相同气象参数输入条件下, 机器学习模型精度普遍优于经验模型, HS 模型、DA 模型与 PM 模型计算结果的拟合性较差。

图 2 为不同温度模型的计算精度对比。由图 2 可以看出,

表2 不同模型参数组合输入方式

模型类型	气象参数组合	模型
温度模型	T_{\max}, T_{\min}, R_a	LSTM1
		TCN1
		DNN1
		ELM1
		GRNN1
		RF1
		HS
		DA
辐射模型	$T_{\max}, T_{\min}, R_a, R_s$	LSTM2
		TCN2
		DNN2
		ELM2
		GRNN2
		RF2
		PT
		MK
质量传输模型	$T_{\max}, T_{\min}, RH, U_2$	LSTM3
		TCN3
		DNN3
		ELM3
		GRNN3
		RF3
		WMO
		TRA

不同温度模型计算精度存在差异, 其中TCN模型在不同模型中的精度最高, 其 $RMSE$ 、 R^2 、 E_{ns} 、 MAE 的中位数分别为0.523 mm/d、0.874、0.870和0.388 mm/d。3种深度学习模型精度普遍优于其余模型, 3种深度学习模型的 $RMSE$ 、 R^2 、 E_{ns} 和 MAE 的中位数分别为0.523~0.674 mm/d、0.788~0.874、0.784~0.870和0.388~0.502 mm/d。3种传统机器学习模型精度优于2种经验模型, 其中RF模型和ELM模型的精度较高, GRNN模型的精度较低。HS模型和DA模型的精度较低, 其 $RMSE$ 、 R^2 、 E_{ns} 和 MAE 的中位数分别为0.964和1.117 mm/d、0.741和0.736、0.560和0.507、0.761和0.897 mm/d。总体而言, 与其余模型相比, 深度学习模型表现出更好的计算精度, 其不同站点的精度均较高, 计算结果的随机性较低。

2.2 不同辐射模型模拟精度对比

表4为不同辐射模型与PM模型计算标准值拟合方程斜率对比。表4显示, 辐射模型的拟合效果明显优于温度模型, 同时TCN模型效果最优, 其不同站点的拟合方程斜率在0.904~1.021之间。3种深度学习模型的拟合效果均优于其余模型, 拟合效果表现为TCN模型>LSTM模型>DNN模型, 拟合方程斜率均在0.85以上。相同气象参数输入条件下, 机器学习模型精度普遍优于经验模型, HS模型、DA模型与PM模型计算结果的拟合性较差, 拟合方程斜率距标准值“1”的偏差较大, 表明经验模型在计算 ET_0 时具有较大的随机性。

图3为不同辐射模型的计算精度对比。由图3可以看出, 不同辐射模型计算精度存在差异, 但精度总体优于温度模型, 其中TCN模型在不同模型中的精度最高, 其 $RMSE$ 、 R^2 、 E_{ns} 、 MAE 的中位数分别为0.319 mm/d、0.952、0.950和0.231 mm/d。

表3 不同温度模型 ET_0 日值与PM模型标准值拟合方程斜率对比

站点	LSTM	TCN	DNN	ELM	GRNN	RF	HS	DA
定陶	0.896	0.901	0.896	0.888	0.841	0.891	0.817	0.767
海阳	0.824	0.839	0.800	0.773	0.754	0.797	1.272	1.314
惠民	0.865	0.871	0.835	0.813	0.778	0.825	0.735	0.739
济南	0.852	0.858	0.844	0.720	0.708	0.791	1.366	1.374
莒县	0.867	0.870	0.850	0.842	0.780	0.844	0.717	0.714
龙口	0.791	0.803	0.782	0.722	0.700	0.763	0.708	0.707
青岛	0.787	0.814	0.775	0.697	0.620	0.749	0.702	0.704
莘县	0.932	0.941	0.924	0.884	0.832	0.910	0.771	0.763
威海	0.749	0.795	0.747	0.683	0.655	0.695	0.588	0.606
潍坊	0.875	0.893	0.863	0.810	0.798	0.839	0.706	0.693

表4 不同辐射模型 ET_0 日值与PM模型标准值拟合方程斜率对比

站点	LSTM	TCN	DNN	ELM	GRNN	RF	HS	DA
定陶	0.947	0.952	0.925	0.925	0.913	0.921	1.188	1.164
海阳	0.907	0.936	0.900	0.887	0.852	0.887	0.742	0.731
惠民	0.952	0.956	0.942	0.942	0.910	0.940	1.297	1.249
济南	0.965	0.974	0.953	0.952	0.868	0.925	0.681	0.686
莒县	0.974	0.976	0.940	0.932	0.879	0.918	1.202	1.253
龙口	0.930	0.940	0.885	0.884	0.845	0.874	0.653	0.691
青岛	0.894	0.901	0.878	0.868	0.834	0.857	0.739	0.748
莘县	0.984	0.987	0.962	0.956	0.946	0.955	1.251	1.275
威海	0.924	0.939	0.903	0.881	0.806	0.880	0.721	0.715
潍坊	0.955	1.021	0.943	0.942	0.908	0.942	0.743	0.746

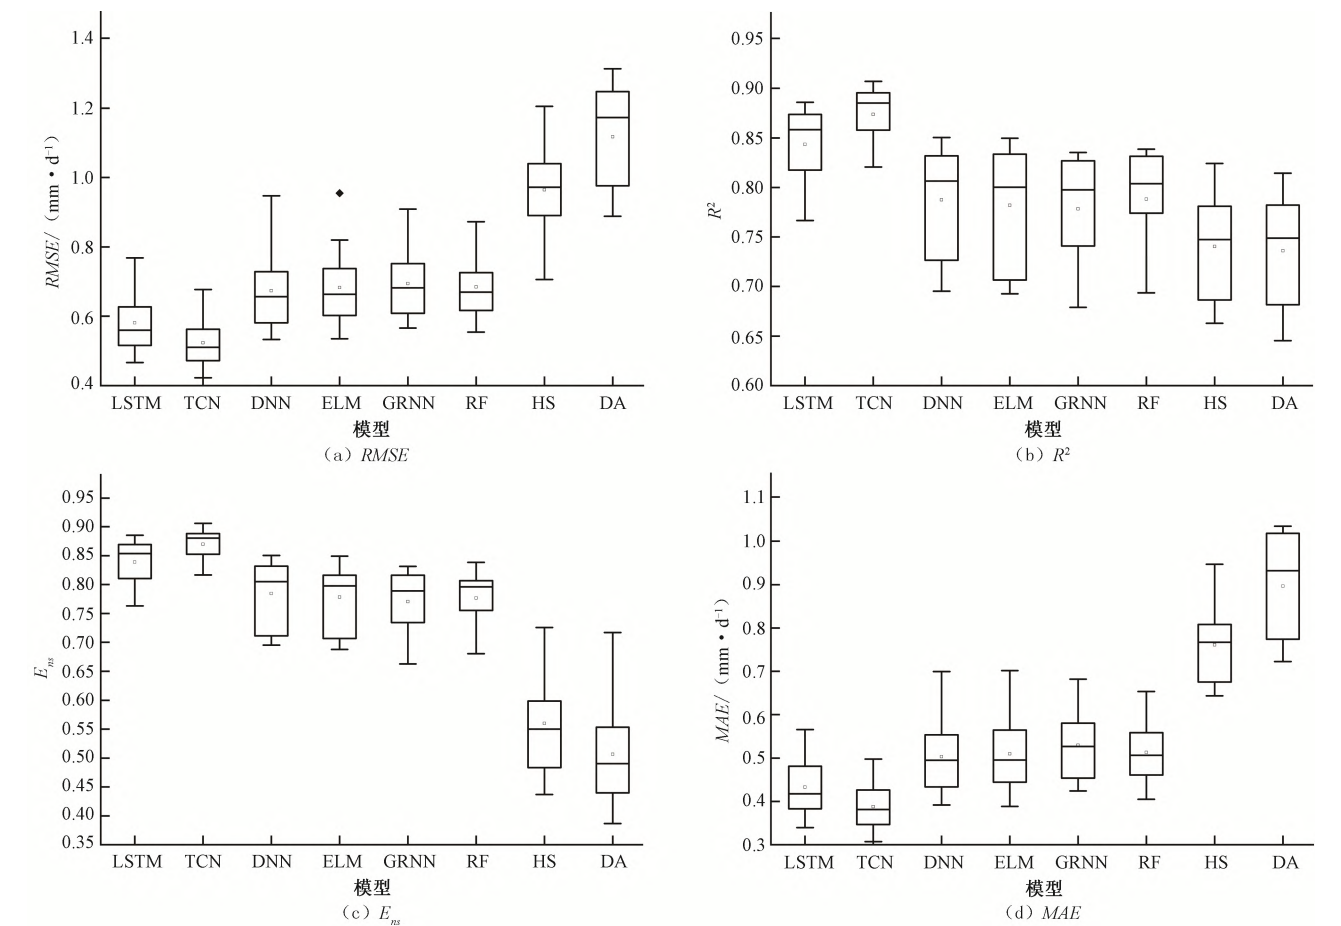


图2 不同温度模型模拟 ET_0 精度对比

3种深度学习模型精度普遍优于其余模型， $RMSE$ 、 R^2 、 E_{ms} 和 MAE 的中位数分别为0.319~0.409 mm/d、0.920~0.952、0.921~0.950和0.231~0.307 mm/d，其中，TCN模型精度最高，LSTM模型精度次之。3种传统机器学习模型精度优于2种经验模型，其中ELM模型和RF模型的精度较高， $RMSE$ 、 R^2 、 E_{ms} 和 MAE 的中位数分别为0.416和0.444 mm/d、0.915和0.907、0.914和0.904、0.330和0.328 mm/d。HS模型和DA模型的精度较低，其 $RMSE$ 、 R^2 、 E_{ms} 和 MAE 的中位数分别为0.726和0.769 mm/d、0.806和0.838、0.738和0.712、0.555和0.601 mm/d。

2.3 不同质量传输模型模拟精度对比

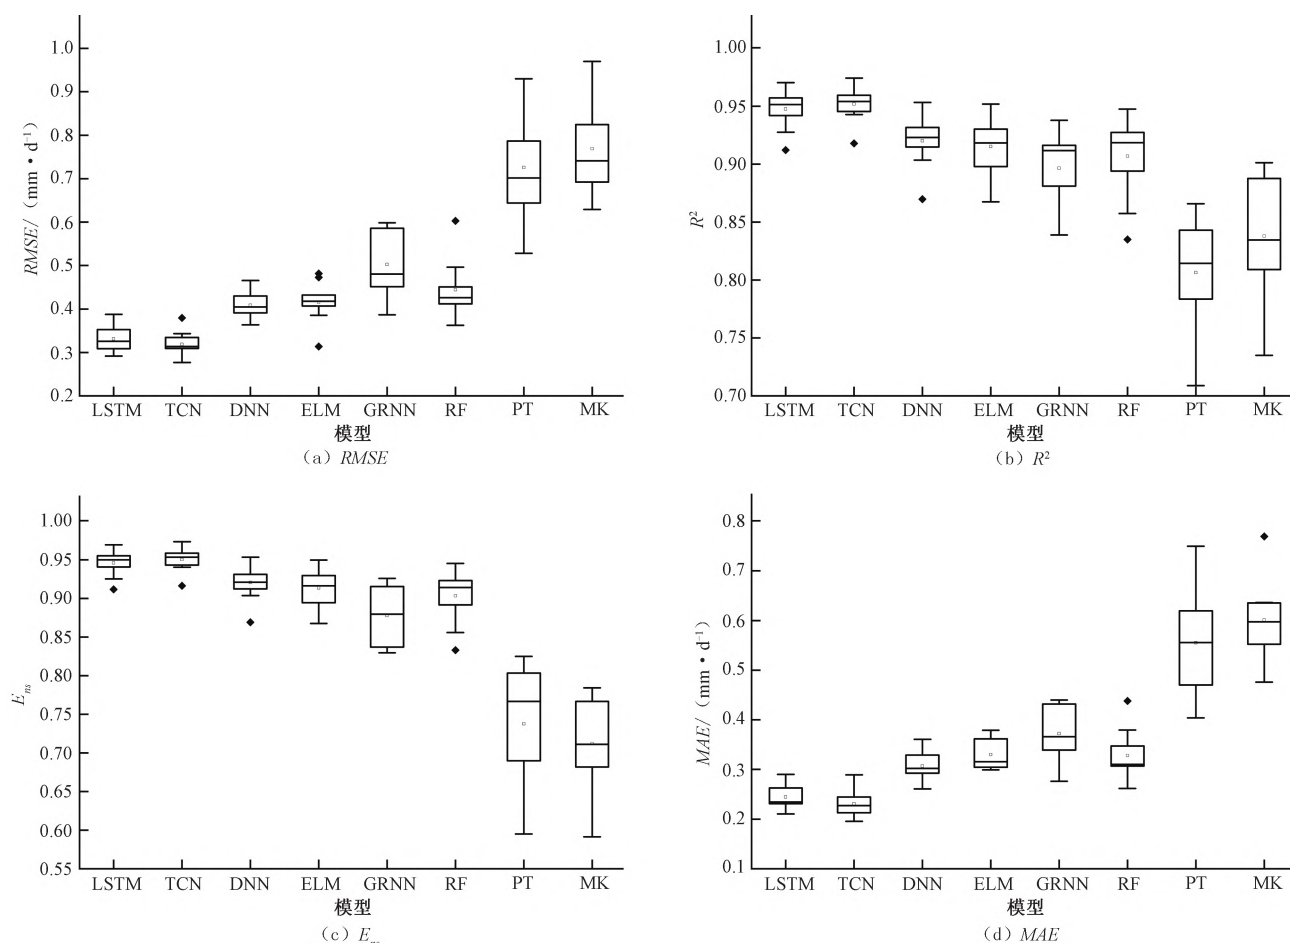
表5为不同质量传输模型与PM模型计算标准值拟合方程

斜率对比。表5显示，质量传输模型的拟合效果介于温度模型与辐射模型之间，同样表现为TCN模型拟合精度最高，其不同站点的拟合方程斜率均在0.886~0.979之间。3种深度学习模型的拟合效果均优于其余模型，拟合方程斜率均在0.85以上。HS模型、DA模型与PM模型计算结果的拟合性较差，拟合方程斜率与标准值“1”的偏差在0.163~0.367之间。

图4为不同质量传输模型的计算精度对比。由图4可以看出，不同质量传输模型的精度明显优于温度模型，但略低于辐射模型。TCN模型在不同模型中的精度最高， $RMSE$ 、 R^2 、 E_{ms} 、 MAE 的中位数分别为0.358 mm/d、0.943、0.939和0.263 mm/d。相同输入参数下的机器学习模型精度普遍优于经验模

表5 不同质量传输模型 ET_0 日值与PM模型标准值拟合方程斜率对比

站点	LSTM	TCN	DNN	ELM	GRNN	RF	HS	DA
定陶	0.931	0.942	0.921	0.914	0.905	0.918	0.821	0.837
海阳	0.904	0.906	0.878	0.868	0.844	0.871	0.738	0.724
惠民	0.942	0.948	0.932	0.911	0.892	0.931	0.762	0.749
济南	0.956	0.964	0.913	0.884	0.862	0.902	0.637	0.655
莒县	0.953	0.959	0.914	0.886	0.878	0.903	0.787	1.215
龙口	0.914	0.929	0.859	0.847	0.816	0.859	0.735	0.721
青岛	0.879	0.886	0.852	0.845	0.818	0.849	0.711	0.750
莘县	0.970	0.979	0.955	0.951	0.945	0.952	0.793	0.798
威海	0.915	0.921	0.857	0.832	0.796	0.846	0.633	0.685
潍坊	0.948	0.951	0.938	0.910	0.904	0.926	0.764	0.749

图3 不同辐射模型模拟 ET_0 精度对比

型,其中3种深度学习模型的精度较高。HS模型和DA模型的精度较低,其 $RMSE$ 、 R^2 、 E_{ns} 和 MAE 的中位数分别为0.851和0.870 mm/d 、0.706和0.740、0.683和0.685、0.731和0.714 mm/d 。

综上所述,深度学习模型精度普遍优于其余模型,其中,TCN模型在不同气象参数输入下均表现出了较高的精度。

2.4 不同模型GPI对比

为综合判定不同输入参数组合下不同模型的计算精度,本文综合比较了24种模型的GPI,结果见图5。由图5可以看出,在不同模型中,辐射模型精度最高,质量传输模型精度次之,温度模型精度较低。TCN2模型在所有模型中精度最高,GPI中位数为1.036,LSTM2模型精度次之,GPI为0.975。温度模型和质量传输模型中,均表现为TCN模型精度最高,GPI分别为-0.006和0.873。相同参数输入下的经验模型精度较低,其中HS和DA模型GPI仅为-2.365和-2.877。

3 讨论

已有研究表明,输入气象参数组合的不同对模型预测 ET_0 的精度起着主要作用^[25]。不同区域研究均表明,辐射数据是保障 ET_0 较高估算精度的关键参数^[26]。Feng等^[27]指出基于温度和辐射参数作为机器学习模型的输入组合,可保证模型较高的精度。3种类型模型表现出的精度由高到低依次为辐射模型、质量传输模型、温度模型,表明辐射是影响山东省 ET_0 变化的

关键因素。董旭光等^[28]指出近50年,日照时数和风速是影响山东省 ET_0 变化的主要因素,这与本文结论基本一致。当仅有温度数据输入时,机器学习模型精度高于经验模型,可满足 ET_0 估算的精度要求。需要指出的是,本文中不仅使用了气温数据(T_{\min} 和 T_{\max}),而且将 R_0 数据作为了温度组合重要的输入参数, R_0 数据可从年日和纬度得到,可近似作为全球太阳辐射,引入 R_0 作为训练数据的输入,提高了基于温度模型的准确性。在中国,温度资料的获取是最为方便的,因此基于温度的机器学习模型可实现实时快捷预报 ET_0 ,从而改善灌溉和水资源管理^[29]。对于质量传输模型,与温度模型相比,引入相对湿度和风速等气候数据,可提高模型精度,但其精度低于辐射模型,因此,对于质量传输模型的应用性有待进一步讨论。

传统机器学习模型参数确定的随机性导致了模型误差较大,影响了最终模型模拟的结果。本文比较了3种深度学习模型与其余传统机器学习模型的精度,指出了3种深度学习模型的精度普遍较高,因此,深度学习模型可以有效避免参数的随机性选取,从而产生随机初始化权值和隐藏偏差,最终避免了非最优解,提高了模型精度^[30]。深度学习模型通过对模型训练数据的学习,从而自行进行数据特征选择,能够更好地揭示数据的客观规律,提高模型精度。TCN模型的广泛应用可为农业、水利、气象部门活动提供数据支撑,保证国家粮食生产及水资源的合理利用。

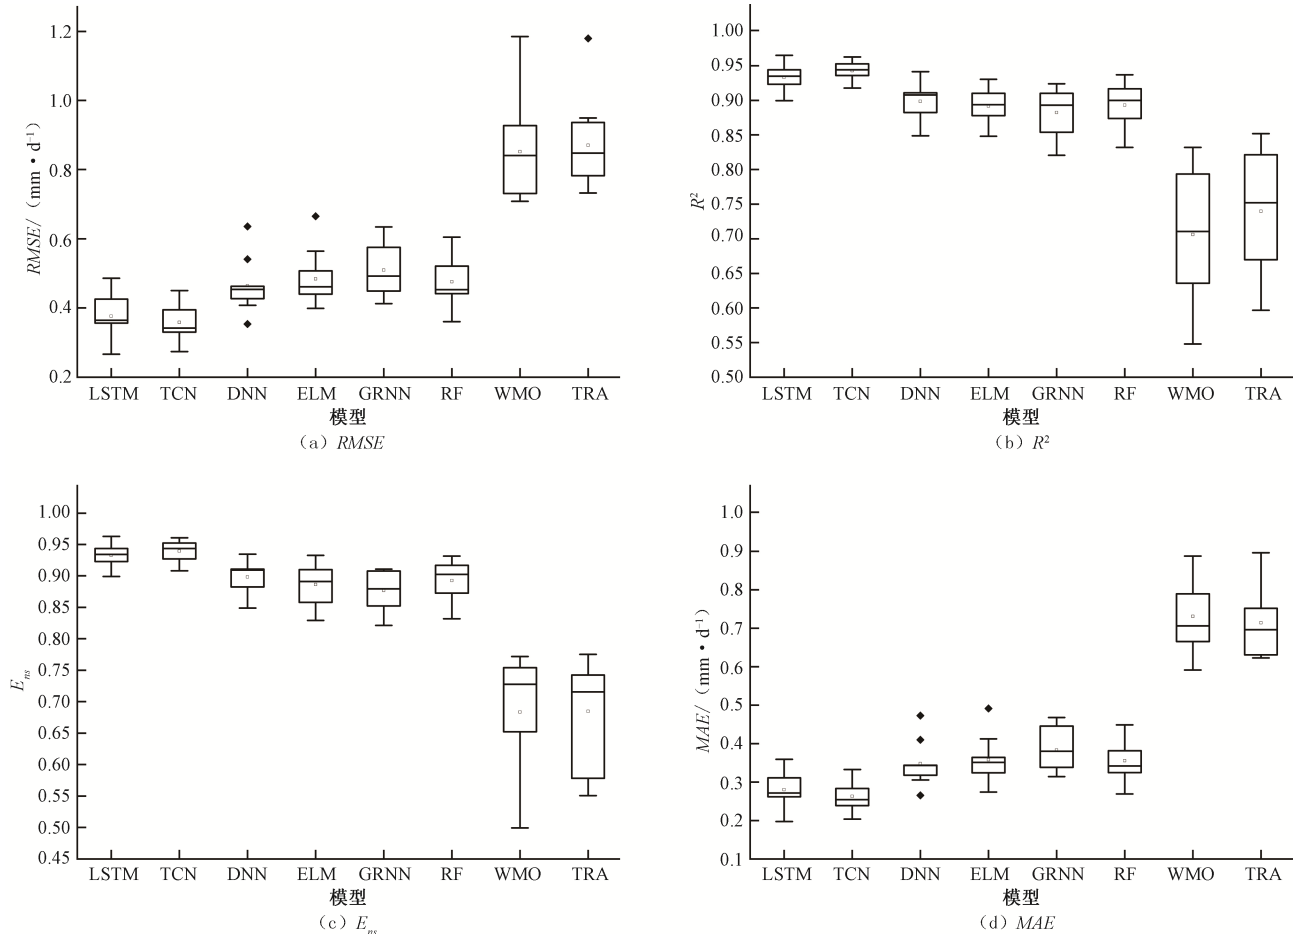


图4 不同质量传输模型模拟 ET_0 精度对比




图5 不同参数输入组合下不同模型GPI对比

4 结论

本文以 LSTM 模型、TCN 模型和 DNN 模型 3 种深度学习模型为基础，与 ELM、GRNN、RF3 种传统机器学习模型和 HS、DA 等 6 种经验模型对比，找到山东省 ET_0 估算的最优模型，得出以下结论：

(1) 3 种深度学习模型精度普遍优于其余模型，TCN 模型具有最高的精度，在不同站点拟合方程斜率最接近标准值“1”， $RMSE$ 、 R^2 、 E_{ns} 、 MAE 的中位数在 0.318~0.523 mm/d、0.874~0.952、0.870~0.950、0.231~0.388 mm/d，TCN 模型在所有模型中 GPI 数值均最高；

(2) 基于辐射的模型优于基于温度和质量传输的模型，TCN2 模型在所有模型中精度最高，其 $RMSE$ 、 R^2 、 E_{ns} 、 MAE

的中位数分别为 0.318 mm/d、0.952、0.950、0.231 mm/d，同时 GPI 达到了 1.036，在所有模型中排名第 1 位。

综上所述，深度学习模型可作为区域 ET_0 估算的推荐模型使用，其中以 TCN 模型精度最高。

参考文献：

- [1] ZHU B, FENG Y, GONG D Z, et al. Hybrid particle swarm optimization with extreme learning machine for daily reference evapotranspiration prediction from limited climatic data[J]. Computers and Electronics in Agriculture, 2020, 173:1–12.
- [2] 黄滢淳, 崔宁博, 陈宜全, 等. 基于不同机器学习模型的川中丘陵区参考作物蒸散量模拟[J]. 中国农村水利水电, 2020(5): 13–20, 27.
- [3] 冯 禹, 崔宁博, 龚道枝, 等. 基于叶面积指数改进双作物系数法估算旱作玉米蒸散[J]. 农业工程学报, 2016, 32(9): 90–98.
- [4] ALLEN R G, PEREIRA L S, RAES D, et al. Crop evapotranspiration guidelines for computing crop water requirements[M]. Rome: Food and Agriculture Organization of United Nation, 1998.
- [5] 李可利, 张 鑫. 基于 ANFIS 的陕西省参考作物蒸散量计算[J]. 自然资源学报, 2020, 35(6): 1 472–1 483.
- [6] CHEN Z J, ZHU Z C, JIANG H, et al. Estimating daily reference evapotranspiration based on limited meteorological data using deep learning and classical machine learning methods[J]. Journal of Hydrology, 2020, 591:125286.
- [7] CAI J, LIU Y, LEI T, et al. Estimating reference evapotranspiration

- with the FAO Penman-Monteith equation using daily weather forecast messages[J]. *Agricultural and Forest Meteorology*, 2007, 145: 22-35.
- [8] 吴 萍,孟昭睿,吴 莉,等. 参考作物蒸散量计算方法在西宁的适用性分析[J]. *中国农村水利水电*, 2018, (6): 18-21, 26.
- [9] ALMOROX J, QUEJ V H, MARTÍ P. Global performance ranking of temperature based approaches for evapotranspiration estimation considering Koppen climate classes[J]. *Journal of Hydrology*, 2015, 528: 514-522.
- [10] 杨永刚,崔宁博,胡笑涛,等. 中国三大灌区参考作物蒸散量温度法模型的修订与适应性评价[J]. *中国农业气象*, 2018, 39(6): 357-369.
- [11] FENG Y, CUI N, ZHAO L, et al. Comparison of ELM, GANN, WNN and empirical models for estimating reference evapotranspiration in humid region of Southwest China[J]. *Journal of Hydrology*, 2016, 536: 376-383.
- [12] 吴宗俊,崔宁博,胡笑涛,等. 基于改进Makkink模型的四川盆地参考作物蒸散量估算[J]. *排灌机械工程学报*, 2021, 39(5): 509-516.
- [13] 褚荣浩,李 萌,倪 锋,等. 13种典型参考作物蒸散量估算模型在安徽省的适用性评价[J]. *节水灌溉*, 2021(9): 61-70.
- [14] DJAMAN K, BALDE A B, SOW A, et al. Evaluation of sixteen reference evapotranspiration methods under sahelian conditions in the Senegal River Valley[J]. *Journal of Hydrology: regional studies*, 2015, 3: 139-159.
- [15] ZHANG J, ZHU Y, ZHANG X, et al. Developing a Long Short-Term Memory (LSTM) based model for predicting water table depth in agricultural areas[J]. *Journal of Hydrology*, 2018, 561: 918-929.
- [16] WANG N, ZHANG D, CHANG H, et al. Deep learning of subsurface flow via theoryguided neural network[J]. *Journal of Hydrology*, 2020, 584: 124700.
- [17] 邢立文,崔宁博,董 娟. 基于LSTM深度学习模型的华北地区参考作物蒸散量预测研究[J]. *水利水电技术*, 2019, 50(4): 64-72.
- [18] BAI S, KOLTER J Z, KOLTUN V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling [DB/OL]. <https://arxiv.org/pdf/1803.01271.pdf>.
- [19] HARGREAVES G H, ALLEN R G. History and evaluation of Hargreaves evapotranspiration equation[J]. *Journal of Irrigation and Drainage Engineering*, 2003, 129(1): 53-63.
- [20] PRIESTLEY C H B, TAYLOR R J. On the assessment of surface heat flux and evapotranspiration using large-scale parameters[J]. *Monthly Weather Review*, 1972, 100(2): 81-92.
- [21] MAKINK G F. Testing the Penman Formula by means of lysimeters [J]. *Instit. Water Engineers*, 1957, 11: 277-288.
- [22] WMO. Measurement and estimation of evaporation and evapotranspiration[M]. Tech. Pap. (CIMO-Rep), 1966: 83.
- [23] 王志臻. 砒砂岩区蒸散发特征及估算模型研究[D]. 北京: 北京林业大学, 2019.
- [24] DESPOTOVIC M, NEDIC V, DESPOTOVIC D, et al. Review and statistical analysis of different global solar radiation sunshine models [J]. *Renewable & Sustainable Energy Reviews*, 2015, 52: 1 869-1 880.
- [25] FAN J, YUE W, WU L, et al. Evaluation of SVM, ELM and four tree-based ensemble models for predicting daily reference evapotranspiration using limited meteorological data in different climates of China[J]. *Agricultural and Forest Meteorology*, 2018, 263: 225-241.
- [26] VALIPOUR M, SEFIDKOUHI M A G, RAEINI M. Selecting the best model to estimate potential evapotranspiration with respect to climate change and magnitudes of extreme events[J]. *Agriculture Water Management*, 2017, 180: 50-60.
- [27] FENG Y, CUI N B, GONG D, et al. Evaluation of random forests and generalized regression neural networks for daily reference evapotranspiration modelling[J]. *Agriculture Water Management*, 2017, 193: 163-173.
- [28] 董旭光,邱 粲,王 静. 近50年来山东省参考作物蒸散量变化及定量化成因[J]. *生态环境学报*, 2016, 25(7): 1 098-1 105.
- [29] LUO Y, CHANG X, PENG S, et al. Short-term forecasting of daily reference evapotranspiration using the Hargreaves-Samani model and temperature forecasts[J]. *Agriculture Water Management*, 2014, 136: 42-51.
- [30] WANG N, ZHANG D, CHANG H, et al. Deep learning of subsurface flow via theoryguided neural network[J]. *Journal of Hydrology*, 2020, 584: 124700.

(上接第66页)

- [12] 刘会学,寇建良,张锁成,等. 不同年龄阶段侧柏林生物量结构分析[J]. *河北林果研究*, 2015, 30(4): 344-347.
- [13] 张万儒. 森林土壤分析方法[M]. 北京: 中国标准出版社, 1999.
- [14] 鲍士旦. 土壤农化分析[M]. 北京: 中国农业出版社, 2000.
- [15] 田大伦,陈书军. 樟树人工林土壤水文-物理性质特征分析[J]. *中南林业学院学报*, 2005, 25(2): 1-6.
- [16] 张晓艳,李琴书. 不同土地利用方式对土壤侵蚀及养分流失的影响[J]. *水土保持研究*, 2018, 25(5): 12-17.
- [17] 孙艳红,张洪江,程金花,等. 重庆缙云山林地枯落物及土壤水文效应研究[J]. *中国水土保持科学*, 2006, 4(3): 31-35.
- [18] 高 鹏,李增嘉,杨慧玲. 渗灌与漫灌条件下果园土壤物理性质异质性及其分形特征[J]. *水土保持学报*, 2008, 22(2): 155-158.
- [19] 刘海军,龚时宏. 喷灌条件下土壤水分入渗的数学模拟[J]. *灌溉排水学报*, 2006, 25(2): 15-19.
- [20] 李 蕊. 不同灌溉方式下林地土壤水分物理性质的初探[J]. *北方园艺*, 2010(17): 16-20.
- [21] 葛新伟,张 霞,王 锐,等. 滴灌条件下酿酒葡萄园土壤速效养分和水分迁移特征[J]. *节水灌溉*, 2017(12): 52-55.