

采用多分类器集成方法的带钢表面缺陷图像识别

张尧, 刘伟巍, 邢芝涛, 颜云辉

(东北大学 机械工程与自动化学院, 辽宁 沈阳 110819)

摘 要: 现有带钢表面缺陷在线识别系统中单个分类器对部分缺陷识别率不高, 并且对训练样本依赖性较大; 针对这一问题, 提出了一种基于并行多分类器集成技术的带钢缺陷图像识别方法. 该方法选择 LVQ 神经网络、RBF 神经网络和支持向量机作为基分类器, 应用加权投票法对基分类器进行集成, 从而实现基分类器能力互补. 实验表明, 采用多分类器集成的带钢表面缺陷图像识别方法可以更准确地对带钢常出现的边缘锯齿、焊缝、夹杂、抬头纹等缺陷进行识别, 能够得到相当或优于任何单个分类器的分类精度, 总体识别率达到 96% 以上.

关 键 词: 带钢; 表面缺陷; 多分类器集成; 机器视觉; 模式识别; 加权投票算法

中图分类号: TP 391.4

文献标志码: A

文章编号: 1005-3026(2012) 02-0267-04

Surface Defect Recognition for Steel Strips by Combining Multiple Classifiers

ZHANG Yao, LIU Weiwei, XING Zhitao, YAN Yunhui

(School of Mechanical Engineering & Automation, Northeastern University, Shenyang 110819, China.

Corresponding author: LIU Weiwei, E-mail: ghostliuww@163.com)

Abstract: To solve the problems that a single classifier recognizes the surface defects of steel strips ineffectively and over depends on training samples, a new method with combination of multiple classifiers was proposed. The LVQ and RBF neural networks, and the support vector machine were used as the basic classifiers. The weighted voting algorithm was applied to integrating these basic classifiers, thus the complementary of the recognition system was realized. The experiments showed that the common surface defects of steel strips such as zigzag edges, welding seams, inclusions and wrinkles can be more effectively recognized by the combined multiple classifiers. The classification accuracy is better than that of a single classifier, with the overall recognition rate above 96%.

Key words: steel strip; surface defect; multiple classifier combination; machine vision; pattern recognition; weighted voting algorithm

带钢在生产过程中, 由于连铸钢坯、轧制设备、加工工艺等多方面的原因, 常在表面形成边缘锯齿、焊缝、夹杂、抬头纹等各种不同类别的缺陷, 这些缺陷是影响带钢表面质量的一个重要因素. 带钢表面缺陷在线识别的难度主要表现在两个方面: ①某种类别缺陷包含其他类别的缺陷, 比如抬头纹中包含夹杂的缺陷成分, ②同一类别缺陷之间的形态差别很大, 比如抬头纹缺陷之间、夹杂缺陷之间的差别较大等; 这就对分类器提出了较高

的要求. 然而, 单个分类器在算法上很难有新的突破, 同时单个分类器及串行分类器集成识别时对训练样本的依赖性又较高, 因此本文针对现有带钢表面缺陷识别方法存在的问题, 提出了基于并行多分类器集成的带钢缺陷图像识别方法.

1 带钢表面缺陷在线识别系统构成

带钢表面缺陷在线识别系统由图像采集装置、图像处理子系统、缺陷识别子系统, 以及产品

收稿日期: 2011-09-01

基金项目: 国家高技术研究发展计划项目(2008AA04Z135); 国家自然科学基金资助项目(50574019); 沈阳市高技术产业发展项目(2010-106).

作者简介: 张尧(1975-), 男, 辽宁沈阳人, 东北大学博士研究生; 颜云辉(1960-), 男, 江苏丹阳人, 东北大学教授, 博士生导师.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. <http://www.cnki.net>

信息数据库构成. 图像采集系统通过 CCD 相机将带钢表面信息转换为图像数字信号, 再由图像处理子系统对图像数字信号进行各种处理, 如滤波、增强和分割等, 然后由缺陷识别子系统对检测到的缺陷进行识别, 并将识别结果信息存入产品信息数据库中, 用以实现后续的带钢产品表面质量评价分析.

2 多分类器集成

多分类器集成是指构建一个分类器的集

合^[1], 并根据基分类器预测进行(加权)投票, 给出新的识别分类结果. 分类器集成的目的是充分发挥每个基分类器的长处, 从而获得比任何单个基分类器都要高的识别率^[2].

2.1 带钢表面缺陷特征提取

在进行缺陷识别时, 要先对带钢表面缺陷图像提取各种特征, 即与分类有关的各种因素. 本文提取了带钢表面缺陷图像的灰度特征、纹理特征、投影特征、变换域特征、几何形状特征以及其他特征等, 如图 1 所示.

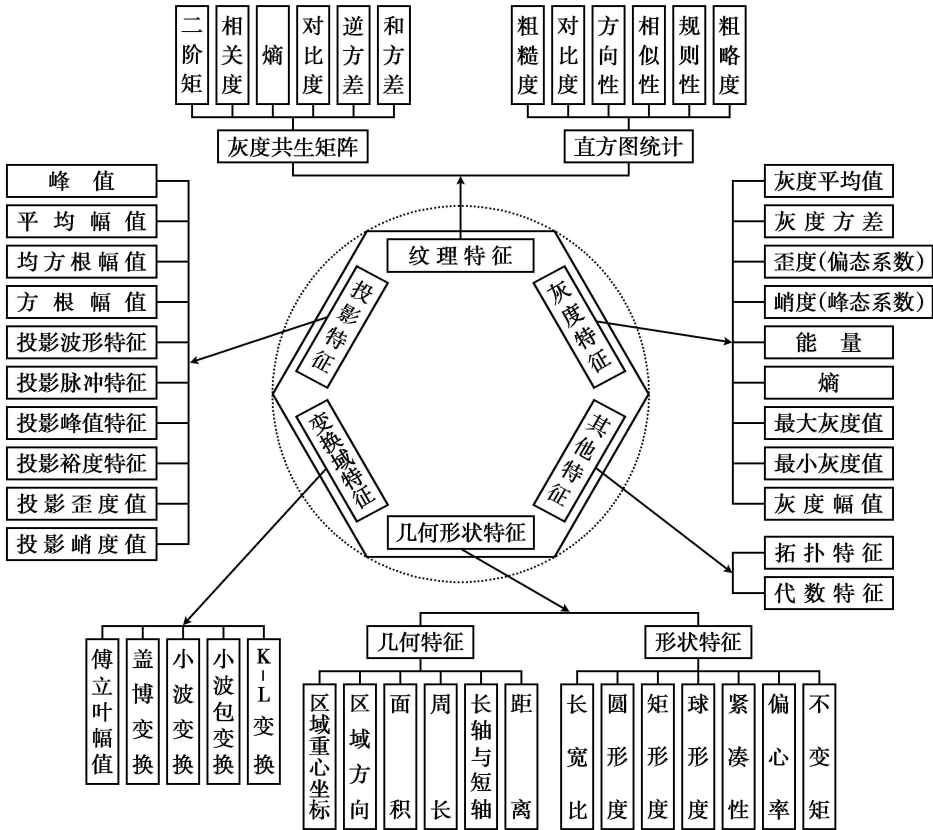


图 1 常用的板带钢表面缺陷图像特征
Fig. 1 Common image characteristics of steel strip surface defects

2.2 基于分类器组合的多分类器集成

当有多个分类器时, 可以对硬分类器或软分类器的输出进行组合, 以实现分类器的集成. 假设多分类器系统中包含 N 个基分类器 $S_i (i = 1, 2, \dots, N)$, 一幅带钢表面缺陷图像分类问题涉及 M 个类别: $C_1 \cup C_2 \cup \dots \cup C_M$. 在带钢表面缺陷图像硬分类中, 基分类器 S_i 对于像元 X 的分类输出是类别标签, 即 $S_i(X) = C_j (j = 1, 2, \dots, M)$; 在软分类中, S_i 的输出结果为 $\{P_i(C_1|X), P_i(C_2|X), \dots, P_i(C_j|X), \dots, P_i(C_M|X)\}$, 其中, $P_i(C_j|X)$ 表示基分类器 S_i 判别像元 X 属于类别 C_j 的概率或隶属度.

多分类器集成有多种方法: 投票法、贝叶斯

法、证据理论法和模糊积分法^[3-9]等. 本文采用加权投票法.

投票法是最常用的一种分类器集成方法, 其基本思想是通过投票方式决定在基分类器输出结果不一致时的模式类别. 加权投票法是赋予各基分类器一定的权值, 即分类能力好的基分类器被赋予较大的权值, 而分类能力差的基分类器赋予较小的权值. 本文采用该方法进行识别分类, 算法步骤如下.

- 1) 将各基分类器的分类混淆矩阵获得的各类别的用户精度作为权值 $w_j^i (i = 1, 2, \dots, N; j = 1, 2, \dots, M)$;
- 2) 各基分类器对未知像元 X 分类后, 将分

类结果相同的各基分类器对该类别的权值相加，即得到像元 X 属于各类别的权值之和；

3) 比较权值之和的大小，将最大值对应的类别作为像元 X 的最终类别标签。

2.3 分类器差异性度量

通常认为，集成多个完全一致的分类器不会对分类性能有任何帮助，因此参与组合的分类器必然存在差异，也就是说，至少其中一些分类器要对其他分类器判断错误的样本做出正确的决策。这种性质称做分类器的差异性，衡量这种差异性的方法被称为差异性度量方法^[7-8]。度量分类器之间的差异性可以帮助选择合适的参与组合的分类器成员，从而构造出更好的多分类器系统。目前，计算基分类器间差异性的方法主要分为两类：一对一差异性度量和非一对一差异性度量。

2.3.1 一对一差异性度量

对于两个分类器 S_i 和 S_j ， N^{11} 与 N^{00} 代表两个分类器均预测正确与均预测错误，即两个分类器均作出正确预测或错误预测的训练样本占总训练样本的比例； N^{10} 为 S_i 预测正确而在 S_j 中预测错误，而 N^{01} 为 S_i 预测错误而在 S_j 中预测正确。基于这些数据计算的分类器差异性度量方法称为一对一的度量方法。先求得分类器两两之间的差异性度量值，然后取平均值即可作为整个分类器集合的分类器差异性度量值。常用的分类器一对一差异性度量有以下几种方法： Q 统计法、相关系数法、不一致度量法、Double-fault 度量法等。

2.3.2 非一对一差异性度量

该类方法指的是直接对所有基分类器进行计算。不同于上述一对一差异性度量方法，非一对一差异性度量并不强调分类器两两之间的关系，而是直接着眼整个分类器集合。

设 $Z = \{z_1, z_2, \dots, z_N\}$ 是一组类别已知的数据，其中 $z_j \in \mathbf{R}^n$ 。可以通过一个 N 维向量 $y_i = [y_{1,i}, y_{2,i}, \dots, y_{N,i}]^T$ 来表示一个分类器 S_i 对该数据集的输出，其中，当 S_i 正确识别 z_j 时， $y_{j,i} = 1$ ，否则 $y_{j,i} = 0$ 。非一对一差异性度量方法多是在这个向量的基础上来进行的。常用分类器的非一对一差异性度量有以下几种方法^[9-19]：评判间一致性法(interrater agreement)、困难度度量法(measure of difficulty)、同时出错差异法(coincident failure diversity)、熵度量法。

3 实验结果及分析

3.1 单个分类器实验

选用 BP 神经网络、LVQ 神经网络、RBF 神

经网络和支持向量机(SVM) 作为基分类器进行实验。选取在生产现场出现频率较高、对表面质量影响严重的 4 类典型缺陷(边缘锯齿、焊缝、夹杂、抬头纹) 作为研究对象，训练和测试样本共 160 幅图像。边缘锯齿：7 幅用于训练，21 幅用于测试；焊缝：8 幅用于训练，22 幅用于测试；夹杂：11 幅用于训练，33 幅用于测试；抬头纹：14 幅用于训练，44 幅用于测试。特征选用 2.1 节所提取的组合特征。4 个单分类器的识别结果如表 1 所示。

表 1 单个分类器识别结果
Table 1 Recognition results by a single classifier %

分类器类型	边缘锯齿	焊缝	夹杂	抬头纹	总识别率
BP	71.4	100	66.7	47.7	66.7
LVQ	66.7	100	90.91	88.64	93.33
RBF	100	100	87.88	75	87.5
SVM	100	100	63.64	95.45	88.33

由表 1 可以看出，对于经常出现的 4 类缺陷，BP 神经网络、RBF 神经网络和支持向量机的(SVM) 识别率没有达到 90%。LVQ 神经网络虽然对夹杂的识别率在 90% 以上，但对边缘锯齿的识别率较低，只有 66.7%。没有一个分类器可以对所有的类别都取得最高的分类精度。因此，各个分类器之间的性能是需要互补的，采用合理的方式组合多个单分类器来提高分类精度是有潜力的。

3.2 并行分类器集成识别实验

3.2.1 基分类器的选择

为了方便描述，首先给单分类器编号：BP，LVQ，RBF 和 SVM 分类器的标签号分别为 1, 2, 3, 4。根据识别结果选取基分类器。

1) 利用一对一差异性度量的 Q 统计法：

$$Q_{ij} = \frac{N^{11}N^{00} - N^{01}N^{10}}{N^{11}N^{00} + N^{01}N^{10}}.$$

Q_{ij} 的绝对值越大，分类器间的差异度越小。根据单分类器识别结果，有 $Q_{12} = 0.746\ 3$ ， $Q_{13} = 0.958\ 7$ ， $Q_{14} = 0.948\ 8$ ， $Q_{23} = 0.803\ 6$ ， $Q_{24} = 0.470\ 6$ ， $Q_{34} = 0.684\ 2$ 。

对一个由 L 个基分类器构成的多分类器系统，它的差异性由 Q_{av} 表示：

$$Q_{av} = \frac{2}{L(L-1)} \sum_{i=1}^{L-1} \sum_{j=i+1}^L Q_{ij},$$

则 123 组合 $Q_{av} = 0.836$ ，124 组合 $Q_{av} = 0.722$ ，134 组合 $Q_{av} = 0.864$ ，234 组合 $Q_{av} = 0.653$ 。

2) 用非一对一差异性度量的困难度度量法进行选择：

$$\theta = \text{Var}(D).$$

D 表示一个输入样本像元 X 正确分类的基分类器占有所有基分类器的比例, 即 $D \in \left\{ \frac{0}{N}, \frac{1}{N}, \dots, 1 \right\}$. θ 值越大, 多分类器系统的分类效果越差.

根据单个分类器的识别结果, 有 123 组合 $\theta_1=0.073$, 124 组合 $\theta_2=0.067$, 134 组合 $\theta_3=0.085$, 234 组合 $\theta_4=0.044$.

根据上面的结果, 选择 LVQ 神经网络、RBF 神经网络和支持向量机作为基分类器进行集成.

3.2.2 基分类器集成结果

用加权投票法对选择后的基分类器进行集成, 其识别结果如表 2 所示.

表 2 多分类器集成识别结果

Table 2 Recognition results by the combined multiple classifiers

缺陷类别 识别率/%	边缘锯齿 100	焊缝 100	夹杂 93.94	抬头纹 93.18
总识别率/%	96.67			

对比表 2 和表 1 可以看出, 本系统所采用的组合特征多分类器的识别率比单个分类器的识别率要高, 即分类器的集成能够有效提高分类器的分类精度.

4 结 论

1) 单分类器对某一类缺陷的识别率或是总识别率不高.

2) 用加权投票法对单个分类器进行集成, 结果表明, 多分类器集成对边缘锯齿、焊缝、夹杂、抬头纹 4 类缺陷的识别率及总识别率都有所提高, 总识别率达到 96% 以上.

参考文献:

[1] Woods K, Kegelmeyer W P, Bowyer K. Combination of

multiple classifiers using local accuracy estimates[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1997, 19(4): 405—410.

[2] Kittler J, Hatef M, Duin R P W, et al. On combining classifiers[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1998, 20(3): 226—239.

[3] Kuncheva L. Combining pattern classifiers: methods and algorithms[M]. Hoboken: Wiley, 2004.

[4] 柏延臣, 王劲峰. 结合多分类器的遥感数据专题分类方法研究[J]. *遥感学报*, 2005, 9(5): 555—563.

(Bai Yan chen, Wang Jin feng. Combining multiple classifiers for thematic classification of remotely sensed data [J]. *Journal of Remote Sensing*, 2005, 9(5): 555—563.)

[5] Nemmour H, Chibani Y. Multiple support vector machines for land cover change detection: an application for mapping urban extensions[J]. *ISPRS Journal of Photogrammetry & Remote Sensing*, 2006, 61(2): 125—133.

[6] 林剑, 鲍光淑, 王润生, 等. 基于模糊密度分解的遥感图像光谱和纹理信息的融合[J]. *电子学报*, 2004, 32(12): 2028—2030.

(Lin Jian, Bao Guang shu, Wang Run sheng, et al. Fusion spectrum and texture information of RS image based on decomposing fuzzy density [J]. *Acta Electronica Sinica*, 2004, 32(12): 2028—2030.)

[7] Kang H J, Doermann D. Selection of classifiers for the construction of multiple classifier systems[C] // *Proceedings of the Eight International Conference on Document Analysis and Recognition*. Washington D C: IEEE Computer Society, 2005: 1194—1198.

[8] Petrakos M, Benediktsson J A. The effect of classifier agreement on the accuracy of the combined classifier in decision level fusion[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2001, 39(11): 2539—2545.

[9] Giacinto G, Roli F. Design of effective neural network ensembles for image classification purposes[J]. *Image and Vision Computing*, 2001, 19(9): 699—707.

[10] Aksela M, Laaksonen J. Using diversity of errors for selecting members of a committee classifier[J]. *Pattern Recognition*, 2006, 39(4): 608—623.